Raport z laboratorium 2 — reprezentacje obrazów w sieci konwolucyjnej

1. Zakres ćwiczenia

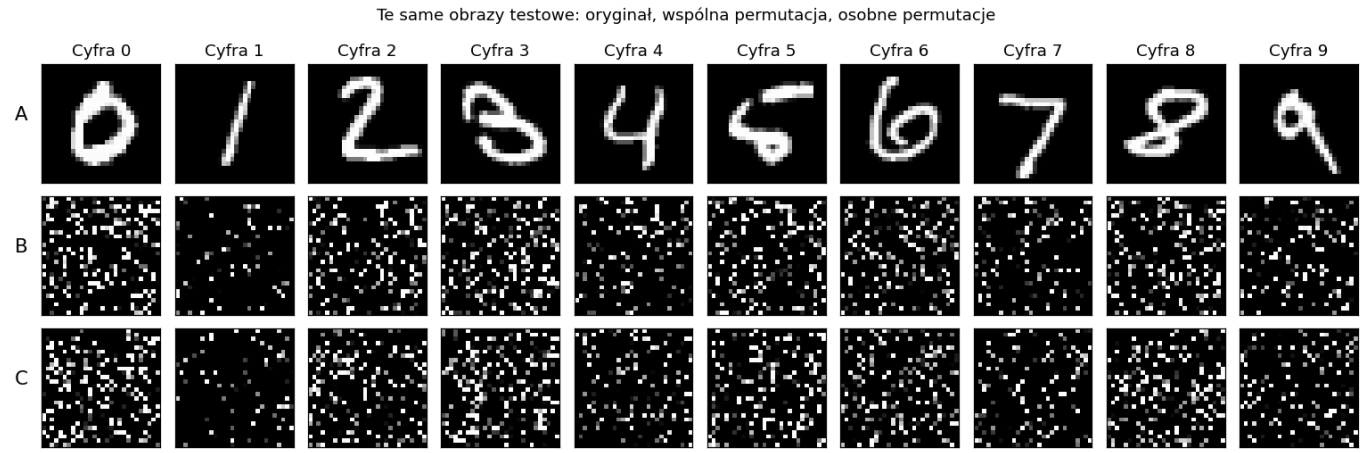
Ćwiczenie obejmowało przygotowanie trzech wariantów obrazów ze zbioru MNIST, wytrenowanie dla każdego z nich sieci CNN z częścią MLP oraz porównanie skuteczności klasyfikacji i reprezentacji powstających w kolejnych warstwach. Celem było sprawdzenie, jak przestawienie pikseli wpływa na uczenie sieci i rozdzielanie klas.

Wykorzystano MNIST: obrazy odręcznych cyfr 0–9, w skali szarości, o rozmiarze 28 × 28 pikseli.

2. Dane i warianty obrazów

Wariant	Przekształcenie	Zachowana informacja
A	Obrazy oryginalne.	Kształt cyfry i naturalne sąsiedztwo pikseli.
B	Jedna losowa permutacja pikseli, wspólna dla wszystkich obrazów treningowych, walidacyjnych i testowych.	Wszystkie wartości pikseli oraz stałe powiązanie nowych pozycji z oryginalnymi.
C	Niezależna losowa permutacja dla każdego obrazu, ustalona przed treningiem i niezmieniana między epokami.	Wszystkie wartości pikseli, ale bez wspólnego układu pozycji między obrazami.

Permutacje nie zmieniały rozmiaru obrazów ani etykiet. Zachowywały też histogram jasności, sumę i średnią wartości pikseli. W B i C cyfry wizualnie przypominają szum, lecz te warianty różnią się tym, czy przestawienie jest wspólne dla całego zbioru.



Do treningu użyto **20 000 obrazów**, do walidacji **5 000**, a do końcowego testu **10 000**. Podział treningu i walidacji był stratyfikowany, czyli zachowywał w przybliżeniu proporcje cyfr. Wartości pikseli przeskalowano z zakresu 0–255 do 0–1.

3. Sieć i warunki treningu

Zastosowana sieć miała dwie warstwy konwolucyjne, operację `Flatten`, dokładnie trzy ukryte warstwy gęste oraz osobną warstwę wyjściową:

Etap	Rozmiar wyjścia dla jednego obrazu
Wejście	1 × 28 × 28
Konwolucja 3 × 3, 16 filtrów + ReLU + MaxPool 2 × 2	16 × 14 × 14
Konwolucja 3 × 3, 32 filtry + ReLU + MaxPool 2 × 2	32 × 7 × 7
Flatten	1568
Warstwa gęsta 1 + ReLU	128
Warstwa gęsta 2 + ReLU	64
Warstwa gęsta 3 + ReLU	32
Warstwa wyjściowa	10 logitów klas

Sieć miała **216 298 uczonych parametrów**. Konwolucje tworzyły mapy cech, pooling zmniejszał ich rozmiar, a `Flatten` zamieniał je w wektor. Warstwy gęste łączyły te cechy, tworząc reprezentację wykorzystywaną do klasyfikacji.

Dla A, B i C trenowano **trzy osobne modele**, każdy na swoim wariancie danych i oceniany na odpowiadającym mu wariancie testowym. Modele miały identyczną architekturę, początkowe wagi, podział danych i kolejność przykładów podczas treningu.

Najważniejsze ustawienia:

- **5 epok** dla każdego wariantu,
- optymalizator **Adam**, learning rate **0,001**, batch size **128**,
- funkcja straty **cross-entropy**,

Do testowania przywracano wagi z epoki o **najniższej stracie walidacyjnej**. Dlatego najlepsza epoka nie musi być tą z najwyższą trafnością walidacyjną.

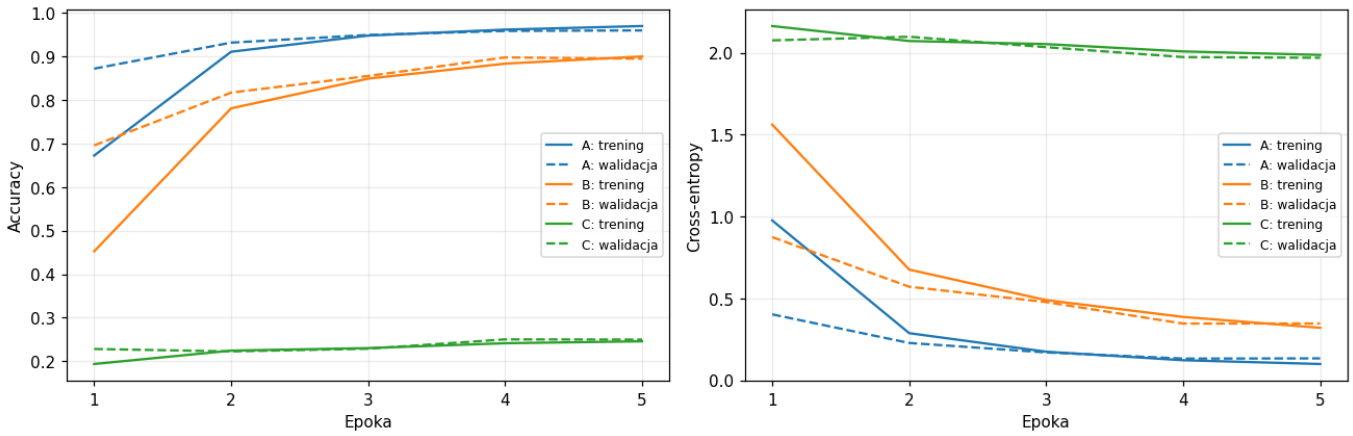
4. Porównanie wyników klasyfikacji

Accuracy oznacza odsetek poprawnych klasyfikacji. Niższa strata cross-entropy oznacza lepszy wynik pod względem wartości przypisywanych prawdziwym klasom.

Wariant	Accuracy testowa	Strata testowa	Liczba błędów na 10 000 obrazów	Wybrana epoka
A — oryginały	**96,43%**	**0,1097**	**357**	4
B — wspólna permutacja	**90,19%**	**0,3255**	**981**	4
C — osobne permutacje	**24,95%**	**1,9627**	**7505**	5

Wspólna permutacja obniżyła trafność względem oryginałów o **6,24 punktu procentowego**, a osobne permutacje o **71,48 punktu procentowego**. Różnica między B i C wyniosła **65,24 punktu procentowego**.

Przebieg uczenia

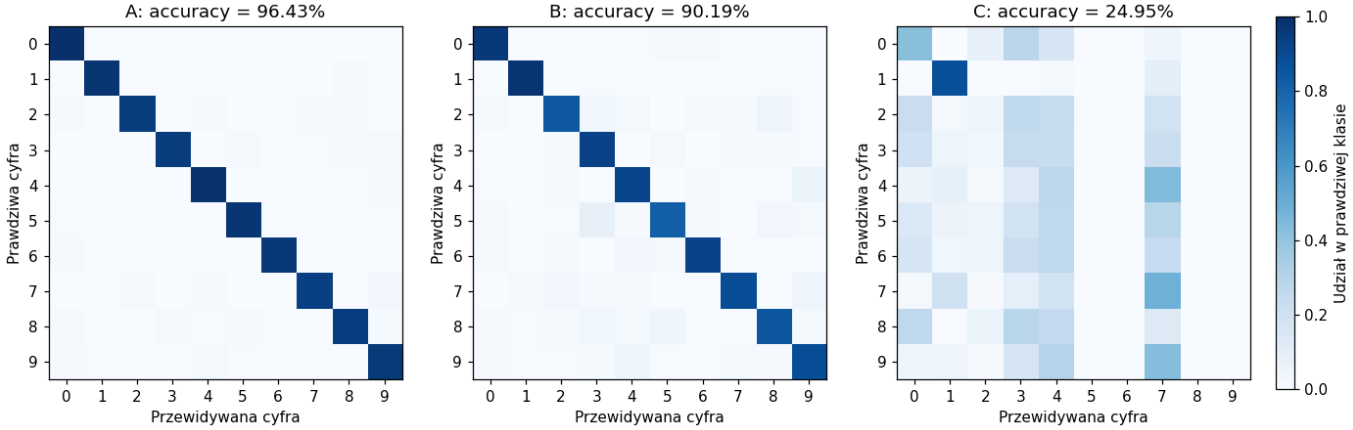


A uczył się najszybciej: już po pierwszej epoce trafność walidacyjna wynosiła 87,18%, a po piątej 95,96%. Strata walidacyjna lekko wzrosła między czwartą i piątą epoką, dlatego do testu wybrano model z czwartej epoki.

B zaczynał od 69,56% trafności walidacyjnej i osiągnął 89,76% w czwartej epoce. Model nauczył się klasyfikować przestawione obrazy, ale przy takim samym czasie uczenia uzyskał słabszy wynik niż A.

C poprawił trafność walidacyjną z 22,82% do 24,98%. Pod koniec treningu trafność treningowa także wynosiła około 25%. Mała różnica między treningiem i walidacją wskazuje, że w tym przebiegu problemem była przede wszystkim trudność nauczenia skutecznej reguły klasyfikacji.

Macierze pomyłek



Wiersze oznaczają prawdziwe cyfry, a kolumny przewidywane. Wartości są znormalizowane w obrębie każdej prawdziwej klasy.

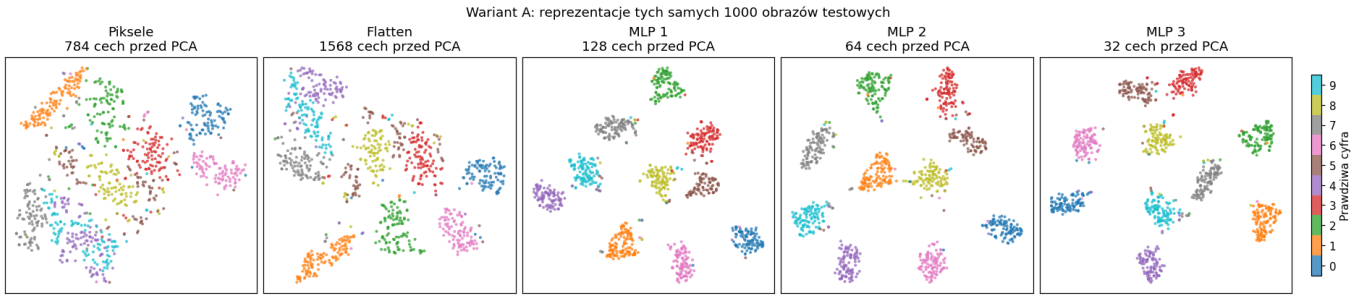
Dla A wyraźnie dominuje przekątna, czyli poprawne rozpoznania. W B przekątna nadal jest mocna, ale więcej wyników znajduje się poza nią. W C większość cyfr jest często mylona; wyróżnia się cyfra **1**, rozpoznawana znacznie lepiej niż pozostałe. Możliwe wyjaśnienie to charakterystyczna liczba jasnych pikseli, jednak sam eksperyment nie potwierdza tej przyczyny.

5. Reprezentacje obrazów — t-SNE

t-SNE służy do przedstawiania wielowymiarowych danych w dwóch wymiarach, z naciskiem na zachowanie lokalnych sąsiedztw. Każdy punkt na wykresie odpowiada jednemu obrazowi testowemu, a kolor oznacza jego prawdziwą cyfrę. Etykiety służyły do kolorowania punktów, nie do obliczania projekcji.

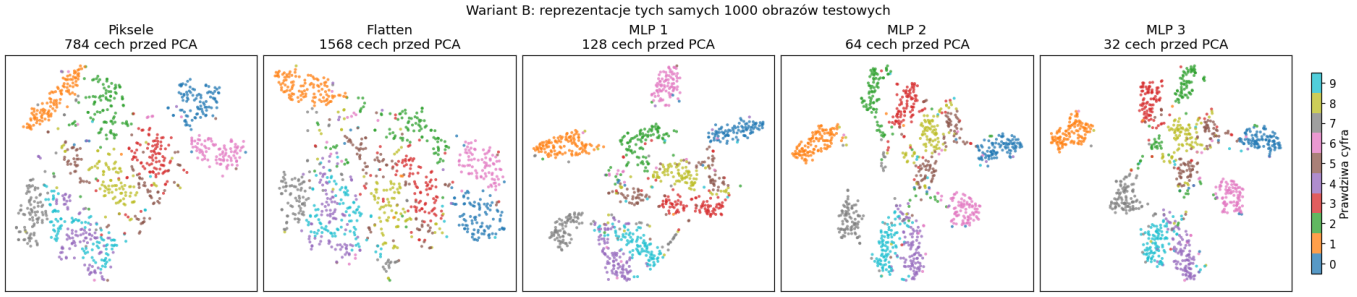
Dla wszystkich wariantów analizowano te same **1000 obrazów testowych**. Porównano surowe piksele oraz aktywacje `Flatten`, `MLP 1`, `MLP 2` i `MLP 3`. Użyto `perplexity=30` i 750 iteracji; reprezentacje o ponad 50 cechach wcześniej redukowano metodą PCA do 50 wymiarów.

A — obrazy oryginalne



Na poziomie surowych pikseli część kolorów się miesza. Po części konwolucyjnej, w panelu `Flatten`, grupy stają się czytelniejsze. W warstwach MLP większość cyfr tworzy wyraźne skupiska o jednym dominującym kolorze. Sieć nauczyła się więc reprezentacji, która lepiej rozdziela klasy niż same wartości pikseli.

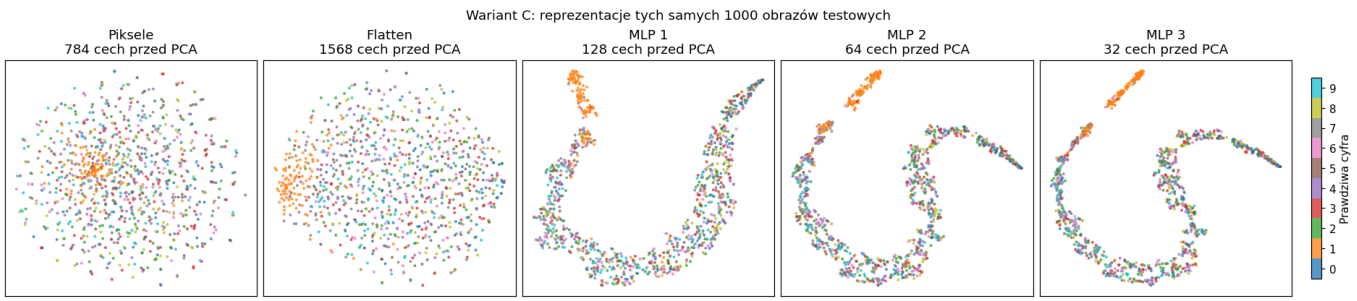
B — wspólna permutacja



Panel `Piksele` wygląda niemal identycznie jak dla A. Wspólna permutacja zachowuje odległości euklidesowe między wektorami obrazów: przestawienie tych samych współrzędnych w obu wektorach nie zmienia sumy kwadratów ich różnic. Notebook potwierdził tę własność numerycznie.

Różnice pojawiają się po części konwolucyjnej: w `Flatten` kolory mieszają się mocniej niż dla A. Warstwy MLP poprawiają separację, lecz np. cyfry **3, 5 i 8** nadal częściowo zajmują wspólny obszar. Jest to zgodne z większą liczbą błędów klasyfikacji.

C — osobne permutacje



Kolory w większości pozostają wymieszane. W warstwach MLP pojawiają się łukowate pasma, ale zawierają one punkty wielu klas. Sam kształt pasm nie oznacza więc dobrego rozdzielenia cyfr. Bardziej odrębny fragment tworzą punkty cyfry **1**, co odpowiada jej lepszemu rozpoznawaniu w macierzy pomyłek.

Każdy panel t-SNE obliczano osobno. Orientacja wykresów i odległości między odległymi skupiskami nie są bezpośrednią miarą jakości modelu; podstawą porównania pozostają wyniki na zbiorze testowym.

6. Wnioski

Jak można było przypuszczać, oryginały uzyskały najlepszą trafność (96.43%), następnie wspólna permutacja (90.19%) i na koniec losowe permutacje - 24.95%.

Wspólna permutacja straciła trafność względem oryginałów zapewne przez fakt zatracenia krawędzi i inne lokalne wzorce. Pomimo tego, według mnie, wypadła i tak bardzo dobrze.

Losowe permutacje również uzyskały poziom 2.5x lepszy od losowego strzelania (10%), co również można nazwać sukcesem. Model szczególnie dobrze rozpoznawał cyfrę `1`, która wyróżniała się przez małą liczbę białych pikseli - jest to też jedyna klasa wyróżniająca się w grafice `t-SNE`. Dobre wyniki uzyskały również cyfry `0` i `7` - chociaż, co ciekawe, klasa `7` ma również wyjątkowo dużo `false-positive`, zwłaszcza w porównaniu do klas `5, 6, 8, 9`, w które model prawie w ogóle nie strzelał.

7. Wykorzystanie AI

Korzystałem z Codex do przygotowania notebooka i zapisanych wyników oraz uporządkowania porównań i wniosków. Wartości liczbowe w raporcie pochodzą z wykonanego eksperymentu.